

ContriLog 개발완료보고서

제 4 회 경남 AI·SW 경진대회 · 지정분야 ② 업무혁신·생산성 향상 AI Agent · 2026-10-05 기준

항목	내용
작품명	ContriLog — 업무 정체를 먼저 찾아 해결까지 연결하는 AI Team Manager
팀명 / 팀원	(작성 필요)
저장소	(작성 필요)
완성도	Level 3 (MVP): 웹 PM 대시보드에서 관찰 → 담당자 확인 → 지원 제안 → PM 승인 → 해결 확인 전 과정이 동작

1. 프로젝트 개요 — 문제, 사용자, 목표

ContriLog 는 프로젝트의 공유 기록을 AI Agent 가 관찰하여 업무 정체를 조기에 발견하고, 담당자에게 직접 확인한 뒤, 필요한 지원을 찾아 PM 에게 제안하고, 사람의 승인 후 실행하며, 실제 해결 여부까지 다시 확인하는 AI Team Manager 입니다.

핵심 원칙: ContriLog 는 사람을 평가하지 않는다. 사람이 판단할 근거와 필요한 개입을 만든다.

- 문제: PM 은 회의록·문서 수정 이력·Task Board·채널 메시지를 직접 살펴야 하고, 막힌 업무는 주간 회의에서야 드러나는 경우가 많습니다. synthetic 프로젝트 P002 재생에서 업무 막힘이 회의에서 처음 언급되기까지 막힘 시작 후 평균 101 시간이 걸렸습니다(6 건, 6 장). 반대로 기록 공백만으로 막힘을 단정하면 로컬·외부 도구에서 일하는 팀원을 잘못 판단합니다.
- 사용자: Primary User 는 회사 프로젝트의 PM·팀장(지원 요청 승인·거절)입니다. 팀원은 확인 질문과 지원 요청을 받는 사용자입니다.
- 성공 기준: 업무 막힘을 회의보다 먼저 확정·기록 공백만으로 막힘이라 단정하지 않음·사람 승인 없는 개입 없음·후속 기록이 있을 때만 해결 처리.
- 차별점(현재 구현 구조 기준): 사람이 회의·Task·문서·메시지를 직접 확인하거나 AI 가 기록을 요약하는 데서 멈추지 않고, 공유 기록 관찰 → 정체 후보 탐지 → 기록 공백만으로 판단하지 않고 담당자에게 직접 확인 → LLM 답장 의미 해석 → 공개 기록 근거 지원 제안 → PM 승인 → 지원 후 기록 재관찰 → 근거 확인 후 해결 → 결과를 Memory 에 반영하는 과정을 하나의 Agent 루프로 수행합니다.

2. 핵심 기능 5 개

① 정체 후보 탐지 판단: 규칙

- 12 시간마다 모든 Task 를 관찰하고, 아래 조건을 모두 만족하면 (Task, 담당자)를 '확인 필요' 후보로 올립니다.
 - Task 가 진행 중·검토 중이고, 마감이 7 일(168 시간) 이내입니다(지난 마감 포함).
 - 마지막 Task 기록 이후 공백이 허용 공백 이상입니다. 허용 공백은 남은 시간의 절반이며 24~72 시간 범위로 제한합니다.
 - 미완료 선행 Task 를 기다리는 중이 아니고, '정상 진행' 답변 후 마감 24 시간 전까지의 기간이 아니며, 같은 담당자에게 질문한 지 48 시간이 지났습니다.
- 팀 전체 공개 기록이 60 시간 이상 끊긴 구간은 공백에서 뺍니다. 후보는 사람 평가도, 막힘 판정도 아닌 '확인이 필요하다'는 뜻입니다.

② 확인 질문 + LLM 답장 해석 판단: LLM: 답장 의미·규칙: 상태 전이

- CheckInTool 로 담당자에게 진행 상황을 묻고, InboxTool 로 답장을 받습니다.
- 로컬 Qwen3 32B(Ollama, JSON Schema 구조화 출력, temperature 0)가 답장을 분류하고 근거 문장을 남깁니다.
 - 담당자 답장: REPORTS_BLOCKED / REPORTS_ON_TRACK / CONFIRMS_COMPLETION / NOT_INFORMATIVE (막힘이면 INTERNAL_ISSUE / EXTERNAL_DEPENDENCY)
 - 지원자 답장: ACCEPTS_SUPPORT / DECLINES_SUPPORT / NOT_INFORMATIVE
- LLM 호출 실패 시 규칙 해석기로 대체합니다. 24 시간 무응답이면 막힘으로 추측하지 않고 '확인 불가'로 기록합니다.
- 개발 후반에 기존 규칙(키워드) 해석기 위에 LLM 의미 해석을 추가했습니다.

③ 근거 기반 지원자 제안 판단: 규칙(단어 겹침)

- CONFIRMED_BLOCK 이고 내부 문제(INTERNAL_ISSUE)일 때만 공개 기록에서 지원 가능한 팀원을 찾습니다. 외부 의존이면 제안하지 않습니다.
- 조건: 담당자가 아닐 것, 막힌 문제의 맥락과 단어가 겹치는 본인 작성 기록이 있을 것, 24 시간 안에 마감인 본인 업무가 없을 것. 관련도가 같으면 담당자를 도운 이전 기록을 우선합니다.

- 점수·순위 없이 선정 이유와 근거 기록을 남깁니다. 관련성은 의미가 아닌 단어 겹침으로 판단합니다(8 장 한계).

④ 승인 실행 + 후속 관찰 판단: 사람 승인 + 규칙

- Agent 는 지원 요청을 PROPOSED 까지만 만들 수 있습니다. PM 이 승인해야 SENT 가 되고, 거절하면 전송하지 않습니다.
- 지원자가 돕겠다고 답해도 해결로 보지 않습니다. 이후 12 시간마다 기록을 다시 봅니다.
- 기준 시각 이후 Task 문서의 수정·해결 리비전(‘수정’ , ‘해결’ , ‘fix’ 등 단어) 또는 Task 상태가 검토 중·완료로 바뀐 기록이 있어야 RESOLVED 입니다.

⑤ Memory + Feedback 판단: 규칙(범위 제한)


- Agent 자신의 판단 결과를 TRUE_POSITIVE / FALSE_POSITIVE / UNRESOLVED / RESOLUTION_SUCCESS 로 저장합니다.
- 검색 키는 상황 특징(마감 구간·공백 비율 구간·Task 상태·팀 전체 휴지기 여부)뿐이며 이름·멤버 ID 가 없습니다.
- 같은 상황의 (FALSE_POSITIVE 수 - TRUE_POSITIVE 수)×12 시간만큼 허용 공백을 완화하되 0~+24 시간으로 제한하고, 마감 24 시간 이내 Task 는 보정하지 않습니다.
- 즉 Agent 자신의 과거 판단 결과로 유사 상황의 확인 시점을 제한적으로 보정합니다.

보조 기능 — 기여 주장(Claim) 검증

- 팀원이 제출한 “제가 이 일을 했습니다” 주장을 atomic claim 으로 나누고 IDEA·EXECUTION·REVIEW·COORDINATION·SUPPORT 유형을 붙입니다.
- 회의 발언·문서 수정·Task·공유 메시지에서 근거를 찾아 VERIFIED / INSUFFICIENT_EVIDENCE / CONFLICTING_EVIDENCE 로 판정합니다(검증 전 상태는 PENDING_VERIFICATION). 기록만으로 부족하면 당사자·상대방에게 추가로 묻는 Interactive Verification 을 거칩니다.
- 점수·순위는 만들지 않습니다. 기여 주장 13 건을 나눈 atomic claim 15 건(P001 10·P002 5)의 판정이 모두 정답과 일치했고, 개인 DM 을 근거로 쓴 경우는 없었습니다.
- 메인 E2E(정체 탐지·지원)와 별개인 보조 기능입니다.

3. Agent 구조 — 6 요소

LLM은 답장 의미만 해석하고, 지원 요청은 PM이 승인해야 실행된다



요소	ContriLog 구현
Goal	막힌 업무를 조기에 발견하고 해결까지 연결
Planning	12 시간 주기로 관찰할 Task 를 고르고, 언제 질문할지(후보 조건·48 시간 재질문 방지), 답장을 언제 다시 확인할지(15 분→8 시간 간격), 지원자를 탐색할지(내부/외부), 언제 후속 관찰할지를 상태에 따라 결정
Reasoning	다중 신호 기반 후보 판단 + Qwen3 답장 의미 해석 + 지원 필요 여부(외부 의존이면 생략)와 해결 근거 판단
Tool Use	관찰 5 종: ProjectStatus·Meeting·DocumentHistory·Message(공유 채널만)·Claim / 행동 3 종: CheckIn·SupportRequest(제안→승인→전송)·Inbox. 모든 호출을 로그로 남김. 정체 관리 E2E(위 그림)는 Claim 을 제외한 관찰 4 종을 사용하며, Claim 은 보조 기능에서만 사용
Memory / State	(Task, 담당자)별 상태 NORMAL → STAGNATION_CANDIDATE → CONFIRMED_BLOCK → RESOLVED, Agent 판단 이력, 범위가 제한된 feedback memory
Feedback / Evaluation	담당자 답장·PM 승인/거절·지원자 답장·후속 프로젝트 기록을 다음 판단에 반영. 성능은 Ground Truth 로 평가(Agent 는 정답에 접근 불가)

4. 대표 E2E — 웹 PM 대시보드 시연 시나리오 ①

P002 ‘배송 상태 웹훅 수신’ (웹훅 서명 오류)을 웹 시연(Qwen3 해석기, Memory ON)으로 끝까지 실행한 실제 기록입니다.

시각	Agent 동작 (괄호는 판단 주제)
5/24 09:00	이상 징후 발견: 마감 135 시간 전, 마지막 Task 기록 후 94 시간 공백(허용 67.5 시간 + Memory 보정 24 시간 = 91.5 시간) → 확인 필요 후보, 담당자 장현우에게 확인 질문 (규칙)
5/24 10:45	답장 “웹훅 서명 검증에서 막혀 있어요 … 스테이징에만 올리면 … 전부 401 이에요” → REPORTS_BLOCKED·INTERNAL_ISSUE (Qwen3) → CONFIRMED_BLOCK (규칙)
5/24 10:45	지원자 탐색: 류다인 — ‘API 게이트웨이 설정: 요청 본문 변환 플러그인 활성화’ 기록, 장현우를 도운 이전 기록, 급한 본인 업무 없음 → 지원 요청 PROPOSED (규칙)
5/24 10:45	PM 이 웹에서 [지원 요청 승인] 클릭 → SENT. 승인 전에는 전송되지 않음 (사람)
5/24 11:30	류다인 “같이 볼게요” → ACCEPTS_SUPPORT (Qwen3). 해결로 보지 않고 후속 관찰 계속 (규칙)
5/27 21:00	후속 리비전 ‘raw body 기준 서명 검증으로 수정’ 관찰 → RESOLVED, 결과를 Memory 에 RESOLUTION_SUCCESS 로 기록 (규칙)

웹 PM 대시보드 (scripts/web_demo.py, frontend/index.html, contrilog/webui/view.py)

- 실행: .venv/bin/python scripts/web_demo.py 로 실행하면 http://127.0.0.1:8790 에서 PM 용 대시보드가 열립니다(Python 내장 웹서버, 외부 라이브러리 없음, 답장 해석 기본값 로컬 Qwen3).
- 화면: 업무 상태 요약(정상·확인 필요·업무 막힘·해결), 지금 확인이 필요한 업무, 7 단계 진행 표시(이상 징후 발견 → 담당자 확인 → 업무 막힘 확인 → 지원자 탐색 → PM 승인 → 지원 요청 → 해결 확인), 담당자와의 대화와 AI 해석, 지원 제안 근거, AI 판단 보정(Memory), 팀 업무 표로 구성됩니다.
- Txx·ACT·RPL·REV·MEM 같은 기술 ID 는 기본 화면에서 숨기고 ‘근거 상세 보기’ 에서 확인합니다.
- PM 은 [지원 요청 승인]/[거절] 버튼으로 직접 결정합니다. 결정 전에는 Agent 의 시간이 멈추고, 시연 모드의 자동 진행도 이 단계에서 멈춥니다.
- 같은 시각에 일어난 판단을 화면에서 한 단계씩 나눠 보여 주는 것은 표시 방식일 뿐입니다. 화면용 adapter(view.py)는 Agent 가 남긴 기록을 읽기만 합니다(adapter 사용 여부와 무관하게 Agent 결과가 동일함을 확인).
- 시나리오 ③(지도 화면)은 지원자 선정 한계 사례로 시연합니다.

5. 사용한 AI·Tool·Data 와 구현·테스트

구분	사용 내용
LLM	Qwen3 32B (Apache 2.0)를 Ollama 로 로컬 실행(사고 단계 off, temperature 0, seed 고정, JSON Schema 구조화 출력). 역할은 답장 의미 해석뿐이며 상태 전이·승인·RESOLVED 조건·Memory 범위는 규칙. 실패 시 규칙 해석기로 대체
Tool	관찰: ProjectStatus·Meeting·DocumentHistory·Message(공유 채널만)·Claim / 행동: CheckIn·SupportRequest·Inbox (8 종, 직접 구현)
데이터	Synthetic 회사 프로젝트 2 개(실제 개인정보 없음). P001 사내 TF 4 명·약 6 주(회의 7·리비전 64·메시지 44·Task 11), P002 물류 서비스팀 5 명·약 8 주(회의 8·리비전 90·메시지 50·회의 발언 53·Task 20). 개인 DM(P001 5·P002 2)은 Agent 가 볼 수 없음
정답(평가 전용)	정체 18 건·기여 20 건·답장 의미 53 건. Agent 코드는 정답에 접근할 수 없음(테스트로 강제)
구현	Python 3.10, Pydantic 2, pytest. 웹: Python 내장 HTTP 서버 + 단일 HTML. 회귀·경계·격리(미래 정보 차단, 개인 DM 차단, 승인 우회 불가, 정답 격리 등)를 포함한 자동화 테스트 714 개 통과, 데이터 검증 (validate_data.py) 통과

대표 사례 (P002 연속 실행, Memory OFF — 항목의 모든 채점 기준 충족 여부, 실패도 그대로 기재)

상황 (Case) → 기대 동작	규칙 해석기	LLM 해석기 (Qwen3)
웹훅 서명 401 (CASE03) → 막힘·지원 제안·승인·해결	성공	성공
학습 중 기록 공백 (CASE01) → 확인 후 정상	성공	성공
“남은 미해결 이슈는 0 건이에요” (CASE11) → 정상	실패(막힘 오판)	성공
“문제 없을 줄 알았는데 … 거기서 멈춰 있어요” (CASE10) → 막힘	실패(놓침)	성공
다른 팀 스키마 확정 대기 (CASE09) → 외부 의존, 지원 제안 없음	실패(지원 제안)	성공

상황 (Case) → 기대 동작	규칙 해석기	LLM 해석기 (Qwen3)
지도 화면 운영 오류 (CASE04) → 적합한 지원자	실패(요구사항 작성자 제안)	실패(동일)
외부 업체 키 미발급 (CASE05) → RESOLVED 금지	실패(무관한 수정을 해결로)	실패(동일)


P002 의 15 개 평가 항목 중 모든 채점 기준을 만족한 항목은 규칙 6 개, LLM 10 개, 오라클(정답 라벨을 그대로 쓴 상한선) 11 개입니다. 지원 요청이 생긴 모든 항목(규칙 5 건·LLM 3 건)에서 요청은 PM 승인 후에만 전송됐습니다.

6. 정량 성과 (synthetic project replay 기준)

아래 수치는 팀이 만든 synthetic 데이터를 Agent 가 처음부터 끝까지 시간 순서대로 관찰한 재생 결과이며, 실제 사용자의 업무 시간을 측정한 값이 아닙니다. 모든 수치는 reports/latest.json(2026-10-05 평가)과 현재 코드 재실행 결과가 일치함을 확인했습니다(LLM 응답은 저장된 캐시 97 건 재사용, 규칙 대체 0 건).

Before — 기존 방식 (주간 회의)	After — ContriLog	차이
주간 회의에서 업무 막힘이 처음 언급됨: 업무 막힘 시작 후 평균 101.2 시간	Agent 가 담당자 확인 후 업무 막힘 확정 (CONFIRMED_BLOCK): 평균 64.5 시간	업무 막힘을 회의보다 평균 36.7 시간(36%) 먼저 확정

P002 synthetic replay · LLM 해석기 · Memory OFF · 회의와 Agent 가 모두 찾은 6 건 기준. 업무 시간이나 생산성의 감소·향상을 측정한 값이 아닙니다.



- 조기 발견: 위 표는 P002(LLM 해석기·Memory OFF)의 실제 업무 막힘 8 건 중 회의와 Agent 가 모두 찾은 6 건을 업무 막힘 시작 시각 기준으로 비교한 것입니다. 회의 시점은 각 막힘을 처음 언급한 회의 발언을 팀이 데이터에서 지정한 값으로, 평가 코드 밖의 수동 매핑입니다.
- 관찰과 질문: 약 8 주 synthetic project replay 에서 Agent 가 211 건의 공개 기록(리비전 90·공유 채널 메시지 48·회의 발언 53·Task 20)을 자동 관찰하고, 그중 확인이 필요한 상황에서 25 회 담당자에게 질문했습니다.

지표 (P002, Memory OFF)	규칙	LLM (Qwen3 32B)	오라클
답장 의미 해석 (P001+P002, 46 건)	31 (67%)	44 (96%)	46
그중 해석이 까다로운 답장 (18 건)	9	17	18
업무 막힘 판정 (15 개 항목)	10	12	12
모든 채점 기준 충족 (15 개 항목)	6	10	11
해결 판정	4/9	5/8	5/8
놓친 실제 업무 막힘 (8 건 중)	3	2	2
확인 질문 수	26	25	25

Memory ON/OFF (LLM 해석기)

지표	P002: OFF → ON	P001: OFF → ON
확인 질문 수	25 → 22	13 → 11
업무 막힘 판정 (항목)	12/15 → 11/15	3/3 → 3/3
놓친 실제 업무 막힘	2 → 3 (CASE06 추가)	0 → 0
해결 판정	5/8 → 4/8	1/1 → 1/1

P002 에서 Memory 는 질문을 3 회 줄였지만, 과거 ‘괜한 확인’ 기록으로 허용 공백이 늘어 CASE06(사유 분류 기준)을 5/31 에 후보로 올리지 않았습니다. 6/3 에 질문했을 때는 답장 전에 Task 가 완료되어, 평가 기간 안에 업무 막힘으로 확정하지 못했습니다. 질문 감소와 탐지 누락 사이의 trade-off 가 확인되었습니다.

평가 공정성: 평가 데이터·정답은 팀이 만들었으므로 수치는 비교·회귀 확인용입니다. LLM 프롬프트 초안(v1)에 평가 데이터의 까다로운 표현 유형이 힌트로 들어간 것을 발견해 폐기했고, 범주 정의만 남긴 v2 의 결과를 공식 수치로 씁니다.

7. 데이터·안전·윤리

- 데이터: synthetic 회사 프로젝트 데이터만 사용하며 실제 개인정보가 없습니다. Agent 는 공유 프로젝트 기록만 사용하고 개인 DM 은 검색·필터·파생 정보로도 볼 수 없습니다.
- 시간 누출 차단: 모든 관찰은 그 시점(as_of)까지의 기록만 보며, 미래의 기록·답장·Memory 에 접근할 수 없습니다(테스트로 검증).
- 사람 평가 금지: 점수·순위·성실도 같은 필드가 없고(있으면 테스트 실패), 정체는 (Task, 담당자)의 현재 상태로 판단합니다. Memory 에도 이름·멤버 ID 가 없어 사람을 프로파일링하지 않습니다.
- 사람 승인: 지원 요청의 최종 실행은 PM 승인 후에만 일어나며, LLM 이 모든 답장을 ‘막힘’ 으로 잘못 읽어도 승인 없이는 전송되지 않음을 테스트로 확인했습니다. LLM 은 사내 서버(로컬)에서 실행해 팀 대화가 외부로 나가지 않습니다.
- 정답 격리: Ground Truth 는 평가 전용이며, Agent 쪽 코드는 정답 모듈·경로에 접근할 수 없습니다(import·파일 접근 검사 테스트).

8. 한계와 향후 계획

1. 지원자 관련성이 단어 겹침에 의존: 의미가 아닌 lexical overlap 으로 관련 기록을 찾아, P002 지도 화면(CASE04, 웹 시나리오 ③)에서 ‘요구사항 정의서: 배송 추적 지도 화면 요구사항 추가’ 작성자를 기술 지원자로 제안했고, 지원자는 원인을 모른다고 답했습니다.
2. 해결 판정 오판: Task 문서의 새 리비전에 ‘수정’ 같은 단서가 있으면 해결 근거로 보므로, 외부 업체 키 미발급 (CASE05)에서 실제 문제와 무관한 ‘미연동 시 안내 문구 수정’ 을 근거로 RESOLVED 로 잘못 판단했습니다.
3. Memory trade-off: 확인 질문을 줄이는 대신 일부 실제 업무 막힘 탐지를 늦추거나 놓칠 수 있습니다(P002 CASE06).
4. 놓치는 유형: 답장이 없는 실제 막힘(CASE08)과 공동 담당 Task 의 부 담당자 막힘(CASE12)을 찾지 못합니다. 또 확인 질문 25 회 중 21 회가 주말·업무시간 외에 발송되었습니다(기준값이 P001 운영 리듬에서 나옴).
5. LLM 해석도 완벽하지 않음: Qwen3 는 46 건 중 2 건의 의미를 틀렸고(완료 보고를 정상 진행으로, 지원 수락을 판단 불가로), 막힘 종류 13 건 중 1 건(내부 문제를 외부 의존으로)을 틀렸습니다.
6. 검증 범위: 정량 평가는 팀이 만든 synthetic 프로젝트 2 개 기반이며, 실제 기업 사용자 실험은 아직 수행하지 않았습니다.

향후 계획: 지원자 관련성·해결 근거 판단에 의미 기반 LLM 적용, 무응답 후보 재확인과 부 담당자 확인, 업무시간을 고려한 질문 시각, Slack·Jira·GitHub 연동으로 실제 팀 파일럿을 운영해 PM 의 확인 시간 변화를 측정합니다.

기업 적용 방향: 현재 외부 협업 도구 Connector 는 구현되어 있지 않습니다. 향후 Jira·GitHub·Slack·Notion 등과 Connector 로 연동해 별도 업무 입력 없이 프로젝트 공유 기록을 관찰하는 구조로 확장할 수 있으며, 실제 기업 파일럿으로 탐지 기준·지원자 추천·해결 판정을 검증한 뒤 PM/팀 단위 SaaS 또는 사내 구축형 Agent 적용 가능성을 검토합니다.

9. 기존자산 · 신규개발분

구분	내용
신규개발 (대회 기간)	저장소 전체를 2026-10-04 23:37(KST) 빈 디렉터리에서 시작해 대회 기간 중 개발(개발 로그와 파일 생성 시각 기준, Git 미사용): 데이터 스키마·synthetic 데이터(P001·P002)와 정답, Tool 8 종, 정체 Agent(후보 탐지·확인·지원 제안·승인 실행·후속 관찰), Memory+Feedback, LLM 답장 해석기, Claim 검증 Agent(보조), 평가 파이프라인, 웹 PM 대시보드(frontend/index.html, scripts/web_demo.py, contrilog/webui/), 자동화 테스트 714 개
기존자산 (외부 공개)	Python, Pydantic, pytest, Ollama, Qwen3 32B(Apache 2.0). 개발 보조 AI 코딩 도구 Claude Code(출처·AI 활용 신고서 기재)
확인 필요	대회 시작(2026-09-29) 이전에 작성한 기획 문서·아이디어 자료가 있는지 (팀 확인 필요)